HNUE JOURNAL OF SCIENCE DOI: 10.18173/2354-1059.2023-0040
Natural Sciences, 2023, Volume 68, Issue 3A, pp. 51-59
This paper is available online at http://stdb.hnue.edu.vn

NHẬN DẠNG HÀNH ĐỘNG SỚM DỰA TRÊN DỮ LIỆU CHUỖI KHUNG XƯƠNG

Phạm Huy Hoàng[1], Bùi Ngọc Dũng[2*], Nguyễn Sơn Anh[1],
Lê Kiến Trúc[2] và Trần Nguyên Hoàng[3]
[1]*Khoa Đào tạo Quốc tế, Trường Đại học Giao thông Vận tải*
[2]*Khoa Công nghệ Thông tin, Trường Đại học Giao thông Vận tải*
[3]*Khoa Công nghệ Thông tin, Trường Đại học Công nghệ Đông Á*

Tóm tắt. Nhận dạng hành động sớm là đưa ra được dự đoán nhãn của hành động trước khi chúng kết thúc hoàn toàn, đây là một ứng dụng để theo dõi y tế, giám sát an ninh, lái xe tự động và tương tác giữa con người với máy tính. Khác với nhiệm vụ nhận dạng hành động truyền thống nhằm mục đích nhận dạng từ một chuỗi hành động đầy đủ, nhận dạng hành động sớm buộc phải đưa ra được nhãn của hành động từ một phần của chuỗi hành động hay với những lần thực hiện hành động chưa hoàn chỉnh. Trong bài báo này, mô hình Knowledge Distillation – Attention-enhanced Adaptive Graph Convolutional Neural Network (KD-AAGCN) được đề xuất nhằm chuyển giao những kiến thức từ Giáo viên sang Học sinh. Kết quả cho thấy độ chính xác của phương pháp đề xuất cao hơn so với phương pháp không sử dụng mô đun Knowledge Distillation.

Từ khóa: nhận dạng hành động sớm, học sâu, chắt lọc kiến thức.

1. Mở đầu

Có hai hướng tiếp cận chính để giải quyết nhiệm vụ nhận dạng hành động là thực hiện nhận dạng trên dữ liệu ảnh RGB hoặc dữ liệu khung xương. Nhược điểm khi tiếp cận nhiệm vụ nhận dạng hành động dựa trên dữ liệu ảnh RGB là mô hình có thể bị ảnh hưởng bởi các yếu tố ngoại cảnh như khung nền video, sự thay đổi anh sáng giữa các khung hình… Khắc phục các nhược điểm này, bộ dữ liệu khung xương được xây dựng bằng việc loại bỏ tất cả yếu tố ngoại cảnh, chỉ giữ lại các chuyển động giữa các khớp và xương. Mô hình KD-AAGCN – Chắt lọc kiến thức được đề xuất trong đề tài này sử dụng dữ liệu khung xương từ tập dữ liệu NTU RGB +D, là một bộ dữ liệu được chuẩn hoá để làm tiêu chuẩn so sánh cho các công trình nghiên cứu.

Nhận dạng hành động truyền thống

Một chuỗi hành động được kết hợp bởi hai yếu tố, đầu tiên là yếu tố không gian, tức là sự kết nối giữa các khớp xương về mặt không gian, thứ hai là yếu tố thời gian, tức là sự liên kết giữa các khung hình với nhau. Nhận dạng hành động truyền thống hay nhận dạng hành động sớm đều mang trong mình hai yếu tố này. Đối với nhận dạng hành động, mạng nơ-ron tích chập (CNN) hay mạng nơ-ron sâu (DNN) khai thác thông tin về yếu tố không gian rất tốt, nhưng lại thường gặp khó khăn khi cố gắng mô phỏng lại thông tin thời gian của chuỗi khung xương. Mặt khác, Nút hồi tiếp có Cổng (Gated Recurrent Unit – GRU), Bộ nhớ dài-ngắn hạn (Long Short Term Memory – LSTM) hay mạng nơ-ron hồi quy (Recurrent Neural Network – RNN) có thể giải quyết việc mô phỏng lại thông tin về mặt thời gian tốt, nhưng lại tỏ ra yếu thế khi không thể

Ngày nhận bài: 21/8/2023. Ngày sửa bài: 22/9/2023. Ngày nhận đăng: 8/10/2023.
Tác giả liên hệ: Bùi Ngọc Dũng. Địa chỉ e-mail: dnbui@utc.edu.vn

hiện được đầy đủ cấu trúc tổng thể của chuỗi khung xương.

Trong [1], mạng tích chập đồ thị không-thời gian (ST-GCN) chứa thông tin không-thời gian lần đầu tiên được giới thiệu. Cách tiếp cận này có thể thu được cả thông tin không gian và thông tin thời gian của chuỗi khung xương. Yan và các cộng sự đã sử dụng ma trận kề để truyền tải trực tiếp thông tin về các kết nối giữa các khớp xương nhằm nắm bắt hiệu quả các mối tương quan trong cấu trúc xương. Tuy nhiên, các tác giả đã giả định các liên kết giữa các khớp là cố định dẫn đến việc không có tính linh hoạt trong việc nắm bắt các thông tin về khung xương người.

Trong [2], với mô hình 2s-AAGCN, đầu vào với hai luồng thông tin được sử dụng để cải thiện những thiếu sót của hướng tiếp cận dựa trên ma trận kề và tập trung vào việc tăng cường mối liên hệ giữa các khớp quan trọng bằng cách kết hợp mạng thần kinh tích chập đồ hoạ (GCN) với mô đun chú ý của kênh không-thời gian (Spatial Temporal Channel Attention) và mô đun thích ứng (Adaptive module).

Chưa dừng lại ở đó, trong [3] nhóm tác giả một lần nữa nâng cao 2s-AAGCN bằng cách trích xuất thêm các thông tin của bộ xương người. Cụ thể, các tác giả đề xuất một mạng MS-AAGCN sử dụng bốn luồng thông tin làm đầu vào, được thử nghiệm trên hai bộ dữ liệu quy mô lớn là: NTU-RGBD [4] và Kinetics Skeleton [5], đồng thời đạt được hiệu suất tốt nhất trên cả hai bộ dữ liệu cho nhiệm vụ nhận dạng hành động trên khung xương người.

Trong [6], Lie và các cộng sự đã đề xuất về RICH, hay các thông tin bậc cao cho cả miền không gian và thời gian, đồng thời sử dụng chúng làm đầu vào cho mạng GCN theo hai cách: 1) Hợp nhất sớm và 2) Hợp nhất muộn. Kết quả thử nghiệm cho thấy với RICH, mô hình cải tiến đã thành công trong việc tăng hiệu suất lần lượn lên 2.55% (RAGCN, CS, LF) và 1.32% (MS-AAGCN, CS, LF) về độ chính xác nhận dạng dựa trên bộ dữ liệu NTU RGB-D 60.

Nhận dạng hành động sớm

Nhận dạng hành động sớm có mối quan hệ chặt chẽ với nhận dạng hành động truyền thống. Thách thức chính mà nhiệm vụ nhận dạng hành động sớm phải giải quyết, chính là việc thiếu thông tin để phân biệt hành động bởi vì không trích xuất được các thông tin từ các chuỗi hành động hoàn chỉnh. Trong [6], Wang và các cộng sự đã dùng kiến thức được học từ chuỗi thông tin đầy đủ được gọi là mô hình giáo viên và thiết kế mô hình học sinh với đầu vào là chuỗi thông tin khuyết thiếu có thể dùng những kiến thức từ mô hình giáo viên nhằm nâng cao hiệu suất. Trong bài này, KD-AAGCN được xây dựng dựa trên mô hình Giáo viên – Học sinh để thực hiện nhiệm vụ nhận dạng hành động sớm..

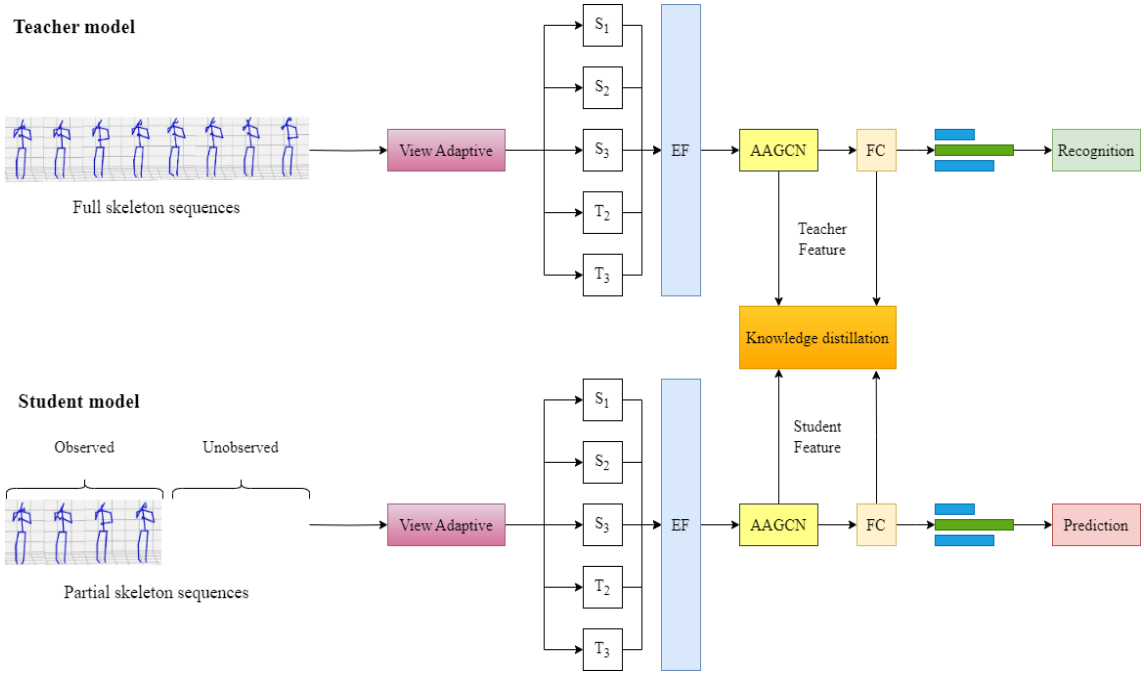
2. Nội dung nghiên cứu

2.1. Mô hình nhận dạng và dự đoán

Mô hình nhận dạng hành động sớm được mô tả trong Hình 1 (trang sau), bao gồm một mạng Giáo viên, một mạng Học sinh và một mô đun Chắt lọc kiến thức (Knowledge Distillation). Nhiệm vụ của mạng Giáo viên là nhằm nhận dạng hành động (tỉ lệ quan sát = 100%) với đầu vào là một chuỗi khung xương đầy đủ, trong khi mục tiêu của mạng Học sinh hướng tới việc dự đoán nhãn của hành động với đầu vào là một chuỗi khung xương không đầy đủ, tuy nhiên, việc sử dụng thông tin được trích xuất từ chuỗi khung xương không đầy đủ này dẫn tới kết quả dự đoán của mạng Học sinh không đạt yêu cầu trong việc dự đoán chuỗi hành động sớm.

Để cải thiện điều này, mô hình chắt lọc kiến thức (Knowledge Distillation) được áp dụng nhằm sử dụng các kiến thức được học từ mô hình Giáo viên giúp mô hình Học sinh có được kết quả chính xác hơn. Đầu tiên, mô hình Giáo viên sẽ được huấn luyện trước và sau đó sẽ được chuyển các đặc trưng của chuỗi dữ liệu hoàn chỉnh thông qua Knowledge Distillation để mô hình Học sinh có thể sử dụng chúng như hướng dẫn cho việc dự đoán hành động. Nhìn, mạng lưới của mô hình Giáo viên và Học sinh được đề xuất là tương đồng nhau. Tuy nhiên, sự khác

biệt chính của 2 mô hình này là dữ liệu đầu vào. Dữ liệu đầu vào của mô hình Học sinh có thể là 20%, 40%, 60%, 80%, và 100% hành động.



Hình 1. VA + Rich + KD-AAGCN

Tổng quan kiến trúc mạng được đề xuất là, sử dụng mô đun Góc nhìn thích ứng (View Adaptive) [8] và thông tin bậc cao (RICH information) [6] để làm phong phú thêm dữ liệu đầu vào cho mô hình GCN, cụ thể trong nghiên cứu này là mô hình AAGCN. Các thông tin giá trị cao được kết hợp sớm tại mô đun Early Fusion (EF – Hợp nhất sớm), sau đó được sử dụng làm đầu vào cho cả hai mô hình Giáo viên và Học sinh. Sau khi trích xuất các đặc trưng từ 5 thông tin này, một mặt các đặc trưng được kết hợp lại trong lớp Kết nối đầy đủ (Fully connected) để nhận dạng hành động trong mô hình Giáo viên, mặt khác trong mô hình Học sinh, các đặc trưng của Học sinh được so sánh với các đặc trưng trong mô hình Giáo viên. Sự so sánh này nhằm mục đích giúp Học sinh có thể học hỏi từ các đặc trưng tốt hơn từ Giáo viên, vốn được trích xuất từ các chuỗi khung xương đầy đủ. Sự so sánh này gọi là Knowledge Distillation (Chắt lọc kiến thức), và hàm mất mát Mean Square Error (MSE – Sai số bình phương trung bình) được sử dụng để đánh giá sự khác biệt này.

2.2. Xây dựng hàm mất mát

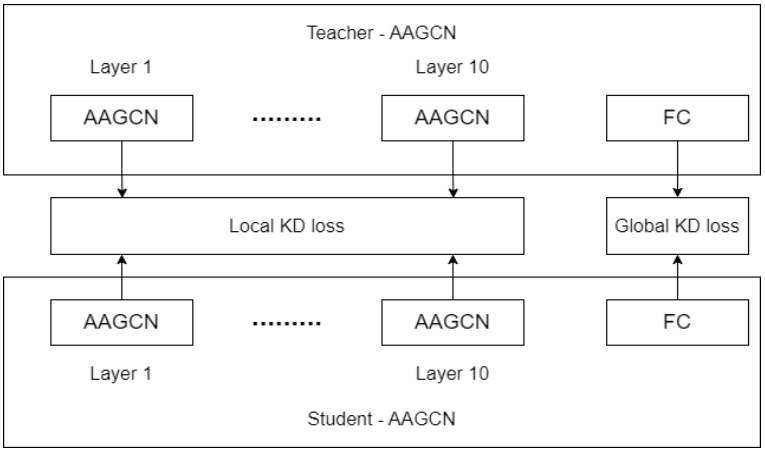
Hàm mất mát cross-entropy được dùng làm hàm mất mát cho cả mạng Giáo viên và Học sinh. Nhiệm vụ của hàm mất mát cross-entropy này là tính toán sự sai số giữa xác suất thực tế và xác suất dự đoán. Hàm mất mát cross-entropy được biểu diễn như sau:

$$\hat{y}_i = \frac{e^{x_i}}{\sum_{i=1}^{c} e^{x_i}} \tag{1}$$

$$L_{cross-entropy} = L(y, \hat{y}) = -\sum_{i=1}^{c} y_i log \hat{y}_i \tag{2}$$

Với $\hat{y}_i$ là xác suất dự đoán cho từng loại hành động, thu được bằng cách sử dụng hàm softmax trên đầu ra của mạng, x_i, c kí hiệu cho số lớp hành động được dự đoán, $\hat{y}_i$ là sự thật nền tảng.

Như được mô tả trong Hình 2, cả hai mạng Giáo viên và Học sinh đều được đào tạo bằng cách sử dụng 10 lớp AAGCN và một mô đun FC, tổng cộng 11 lớp được xem xét từ hai mạng. Vì vậy, mô đun Chắt lọc kiến thức cần được sử dụng để so sánh các đặc trưng đầu ra tại từng lớp của 11 lớp này.



Hình 2. Mô hình Knowledge Distillation

Trong mô đun Chắt lọc kiến thức, hàm mất mát sẽ được chia ra làm 2 phần là hàm mất mát cục bộ (Local KD loss) và hàm mất mát toàn cục (Global KD loss):

- Hàm mất mát cục bộ được sử dụng để tính toán sự khác biệt giữa các đặc trưng được trích xuất từ 10 lớp AAGCN của mô hình Giáo viên và mô hình Học sinh.
- Hàm mất mát toàn cục được sử dụng để tính toán sự khác biệt tại lớp Kết nối đầy đủ (FC) của mô hình Giáo viên và Học sinh.

Trong [7], các tác giả sử dụng MMD cho mô đun Chắt lọc kiến thức bởi sự khác biệt về kích thước đầu ra đặc trưng giữa mô hình Giáo viên và Học sinh. Tuy nhiên, trong đề tài này cả hai mạng Giáo viên và Học sinh đều sử dụng mô hình AAGCN và kích thước đầu vào là giống nhau, dẫn tới các đặc trưng được trích xuất có cùng kích thước. Hàm mất mát Mean square error (MSE) hoạt động rất tốt khi so sánh sự khác biệt của từng thành phần giá trị giữa hai đối tượng, ở đây là đầu ra đặc trưng của hai mô hình Giáo viên và Học sinh.

Công thức hàm mất mát MSE được biểu diễn như sau:

$$MSE(X,Y) = \frac{1}{N}\sum_{i=1}^{N}(x_i - y_i)^2 \tag{3}$$

Hàm mất mát trong mô đun Chắt lọc kiến thức:

$$L_{KD} = \sum_{i=1,2,\dots,11} MSE(S_i, T_i) \tag{4}$$

Trong đó, $\boldsymbol{i \in 1, 2, \dots, 11}$ biểu diễn chỉ số của từng lớp AAGCN, $\boldsymbol{S = \{S_1, S_2, \dots, S_{11}\}}$ là tập hợp của các đặc trưng qua mỗi lớp AAGCN của mô hình Học sinh và $\boldsymbol{T = \{T_1, T_2, \dots, T_{11}\}}$ là tập hợp của các đặc trưng qua mỗi lớp AAGCN của mô hình Giáo viên.

Từ đó, hàm mất mát tổng quát của mô hình KD – AAGCN có công thức như sau:

$$L_{total} = \alpha \cdot L_{prediction} + \beta_1 \cdot L_{local\ KD} + \beta_2 \cdot L_{global\ KD} \tag{5}$$

$\boldsymbol{\alpha, \beta_1, \beta_2}$ lần lượt là hệ số của hàm mất mát dự đoán, hàm mất mát cục bộ và hàm mất mát toàn cục. Các hệ số này quyết định độ quan trọng của các hàm mất mát.

2.3. Kết quả

Thí nghiệm được chạy trên máy tính có cạc đồ họa GeForce RTX 3080Ti, chạy trong môi

trường Visual Studio Code 1.78 và sử dụng thư viện PyTorch 1.1 với ngôn ngữ lập trình Python 3.8.

2.3.1. Dữ liệu

Dữ liệu sử dụng cho quá trình thí nghiệm là bộ dữ liệu NTU-RGB+D 60 được cung cấp trong [4]. Bộ dữ liệu này chứa 56880 mẫu về chuyển động của con người, với tổng cộng 60 hành động. Các kiểu dữ liệu trong bộ dữ liệu này bao gồm chuỗi ảnh RGB, chuỗi bản đồ sâu, chuỗi khung xương 3D và chuỗi hình ảnh hồng ngoại. Trong bài viết này, mọi thí nghiệm đều chỉ sử dụng chuỗi khung xương 3D, chứa 25 nút khớp xương người cho mỗi hành động làm đầu vào.

Trong [7], các tác giả cung cấp bộ dữ liệu này đề xuất 2 benchmarks để huấn luyện mô hình:

- Cross – subject (X-sub): bộ dữ liệu sẽ chia benchmark này thành 2 phần là tập huấn luyện (với 40320 video) và tập kiểm tra (với 16560 video), và những người xuất hiện trong 2 tập dữ liệu này là khác nhau.
- Cross – view (X-view): tập huấn luyện chứa 37920 video được ghi bởi camera 2 và camera 3, và tập kiểm tra chứa 18960 video được ghi bởi camera 1.

Trong đề tài này, X-sub sẽ được chú trọng bởi tính thách thức và thực tế hơn khi mà những người thực hiện hành động ở tập dữ liệu huấn luyện sẽ khác với những người thực hiện hành động ở tập kiểm tra.

Cross – Subject (CS): tập kiểm tra và tập huấn luyện được chia theo mã định danh (ID) của từng hành động. Ở đây, tập ID của tập huấn luyện là (1, 2, 4, 5, 8, 9, 13, 14, 15, 16, 17, 18, 25, 27, 28, 31, 34, 35, 38) và tập ID của tập kiểm tra là các mã ID còn lại.

Trong [2], các tác giả xử lí dữ liệu như sau, mỗi mẫu hành động thường có 2 người tham gia, và nếu số lượng người ít hơn 2 tại bất kì mẫu hành động nào thì nó sẽ gán giá trị 0 cho người thứ 2. Số lượng khung hình tối đa của mỗi mẫu là 300. Với những mẫu ít hơn 300 khung hình, sẽ tiến hành lặp lại các khung hình cho đến khi số lớp bằng 300.

Dữ liệu không đầy đủ

Trong [7], nhóm tác gia đã coi mỗi video là một chuỗi hành động hoàn chỉnh và phân chia nó thành N phân đoạn nhỏ hơn. Với n (n = 1, 2, …, N) lớp đầu tiên tạo thành một phần video không đầy đủ có mức độ là n, tỉ lệ quan sát được xác định là n/N. Trong bộ dữ liệu đầy đủ, những mẫu có ít hơn 300 khung ảnh sẽ lặp lại dữ liệu của chúng cho đến khi đủ 300 khung. Do đó, có hai kiểu dữ liệu không đầy đủ được sử dụng cho mô hình Học sinh:

- Không lặp lại dữ liệu không đầy đủ. Ví dụ, tỉ lệ quan sát chuỗi hành động là 20% và số lượng khung hành động là 100 khung thì chỉ có 20 khung hình đầu tiên được giữ lại, các khung còn lại được gán giá trị bằng 0, tức là không lặp lại bất kì khung hình nào của hành động này.
- Lặp lại các dữ liệu không đầy đủ. Lấy ví dụ bên trên, với hành động chứa 100 khung hình, tỉ lệ quan sát là 20%, 20 khung đầu biểu diễn hành động được giữ lại và 80 khung tiếp theo được gán giá trị bằng 0. Coi 100 khung hình là một chuỗi hành động hoàn chỉnh, và tiến hành lặp lại chúng hai lần cho tới khi đạt 300 khung hình. Như vậy, tổng số khung hình quan sát được sẽ là 60 khung hình, được chia thành ba phân đoạn.

Trong bài viết này, kiểu dữ liệu không đầy đủ đầu tiên được sử dụng trong quá trình thí nghiệm.

2.3.2. Kết quả

Kết quả thực nghiệm dựa theo hàm mất mát tổng quát (5), việc thay đổi các hệ số $\boldsymbol{\alpha, \beta_1, \beta_2}$ làm thay đổi mức độ ảnh hưởng của các thành phần trong hàm mất mát, từ đó dẫn tới các kết quả khác nhau. Vì tính cấp thiết và thời gian có hạn, các giá trị cố định cho ba tham số này lần lượt là $\mathbf{0.5, 0.5, 0.5}$ được sử dụng. Không có cơ sở lí thuyết nào để thực hiện việc chọn giá trị

cho các tham số này, các giá trị hoàn toàn là ngẫu nhiên và được đánh giá dựa trên kết quả của thực nghiệm.

Ngoài ra, chỉ benchmark Cross-Subject cùng tỉ lệ quan sát dữ liệu là 20% được đánh giá trong bài báo này.

Mô hình Giáo viên với dữ liệu đầy đủ

Bảng 1. Phương pháp huấn luyện Giáo viên và kiểm tra kết quả nhận dạng hành động (EF: early fusion)

Method	CS(%)
AAGCN (EF) [6]	87.78%
VA + Rich + 1s-AAGCN	87,88%

Trong [3], MS-AAGCN đạt được 90% trên bộ so sánh Cross-Subject. Lie và các cộng sự đã tuỳ chỉnh MS-AAGCN thành 1s-AAGCN, tức là MS-AAGCN kết hợp với Hợp nhất sớm (Early Fusion), việc hợp nhất bốn luồng thông tin đầu vào thành một khiến kết quả nhận dạng giảm đi, còn 87.78% [6], tuy nhiên, thời gian cần thiết để huấn luyện mô hình giảm đi đáng kể khi không cần tới bốn mô hình AAGCN độc lập cho bốn luồng thông tin đầu vào. Trong đề tài này, mặc dù chỉ sử dụng một luồng thông tin (J-stream) nhưng khi kết hợp với mô đun Góc nhìn thích ứng (VA) và Thông tin bậc cao (RICH), hiệu suất đã được cải thiện nhẹ và đạt được 87.88%.

Mô hình Học sinh với mô đun Chắt lọc kiến thức

Kĩ thuật Giảm số mẫu (Downsampling) cũng được sử dụng để làm giảm thời gian cần thiết trong quá trình huấn luyện. Giảm số mẫu chính là quá trình giảm tốc độ lấy mẫu theo hệ số nguyên, tuy nhiên, chỉ được sử dụng trên tập dữ liệu huấn luyện. Đối với tập dữ liệu kiểm tra, cần phải sử dụng tập đầy đủ không giảm mẫu để đưa ra so sánh công bằng với các nghiên cứu khác trong cùng lĩnh vực. Đồng thời, trong quá trình Giảm số mẫu, các mẫu được đưa vào huấn luyện phải được chọn một cách ngẫu nhiên, tức là tập dữ liệu được sử dụng tại epoch n phải khác với epoch n+1. Việc chọn ngẫu nhiên các mẫu đưa vào huấn luyện tạo ra sự công bằng với mọi mẫu và mô hình có thể tiếp xúc được tất cả các mẫu có trong bộ dữ liệu đầy đủ và mô hình sẽ được huấn luyện tốt hơn.

Gọi K là tỉ lệ Giảm số mẫu, kết quả được so sánh trong Bảng 2:

Bảng 2. So sánh kết quả tỉ lệ nhận dạng với tỉ lệ khác nhau của K trong mô hình Học sinh (VA+RICH+1s-AAGCN: Học sinh không có mô dun Chắt lọc kiến thức, VA+RICH+KD-AAGCN: Học sinh có mô đun Chắt lọc kiến thức, OR: tỉ lệ quan sát, CS: Cross-Subject benchmark)

Method	Observation Ratio (OR = 20%) / CS(%)
VA + Rich + 1s-AAGCN, K=1	34,97%
VA + Rich + 1s-AAGCN, K=5	27,84%
VA + Rich + KD-AAGCN, K=5	29,99%

Bảng 3. So sánh thời gian huấn luyện với tỉ lệ Giảm số mẫu K khác nhau:

Method	Training time
VA + Rich + 1s-AAGCN, K=1	50 min/epoch
VA + Rich + 1s-AAGCN, K=5	13 min/epoch
VA + Rich + KD-AAGCN, K=5	~13 min/epoch

Kết quả tỉ lệ nhận dạng và thời gian huấn luyện mô hình cần thiết được mô tả trong bảng 2 và Bảng 3. Một mặt, khi sử dụng Giảm số mẫu với mô hình Học sinh không có mô đun Chắt lọc kiết thức, tỉ lệ chính xác giảm từ 34.97% xuống 27.84% với K=5, tức là giảm đi 7,13%, nhưng đổi lại thời gian cần thiết để huấn luyện mô hình giảm từ 50 phút mỗi epoch xuống còn khoảng 13 phút. Mặt khác, mặc dù chỉ là thử nghiệm khi sử dụng kĩ thuật Giảm số mẫu nhằm tối ưu thời gian cần thiết huấn luyện mô hình, mô hình Học sinh với mô đun Chắt lọc kiến thức đạt được kết quả 29.99%, cải thiện được 2.15% so với mô hình Học sinh không có mô đun Chắt lọc kiến thức. Điều này chứng minh được việc kết hợp mô đun Chắc lọc kiến thức để truyền tải kiến thức từ Giáo viên sang Học sinh là hiệu quả. Bảng 4 so sánh kết quả đạt được trong bài báo này với các nghiên cứu liên quan.

Bảng 4. So sánh kết quả của phương pháp đề xuất với một số phương pháp khác

Method	**Observation Ratio (OR = 20%) / CS (%)**
RL+LSTM[9] (TCSVT 2020)	35,56%
MTLN[10] (TIP 2020)	8,34%
RNN[10] (TIP 2020)	7,07%
MS-LSTM[10] (TIP 2020)	27,41%
Local+LGN[10] (TIP 2020)	32,12%
Dear-Net[11] (TMM 2021)	32,72%
AGCN-AL[12]	38,18%
VA + Rich + KD-AAGCN, K=5	**29,99%**

Như được trình bày trong Bảng 4, kết quả thực nghiệm của phương pháp đề xuất trong đề tài này được in đậm. Sử dụng kĩ thuật Giảm số mẫu với tỉ lệ K=5, phương pháp đề xuất đạt kết quả cao hơn [10], nhưng thấp hơn kết quả trong [11], [12]. Tuy nhiên, đối với mô hình Học sinh không có mô đun Chắt lọc kiến thức và không sử dụng Giảm số mẫu, tức là K=1, đạt được kết quả 34.97%, được kì vọng sẽ cao hơn các kết quả ở trên, không chỉ với Tỉ lệ quan sát (OR) 20%, mà còn với 40%, 60%, 80% và 100% khi kết hợp mô đun Chắt lọc kiến thức.

Theo khảo sát của nhóm tác giả, đến thời điểm hiện tại không có nhiều nghiên cứu trước đó dựa vào dữ liệu bộ khung xương của con người để nhận dạng hành động và cần tỉ mỉ, kiên nhẫn trong việc chọn tài liệu sử dụng cùng một bộ dữ liệu và số liệu đánh giá để so sánh. Trong các nghiên cứu đã công bố, các tác giả hầu hết sử dụng chuỗi hình ảnh RGB để làm dữ liệu đầu vào cho mô hình huấn luyện, trong khi những năm gần đây, dữ liệu khung xương người nổi lên là bộ dữ liệu thường được sử dụng làm đầu vào cho mô hình. Vì vậy, hầu hết các nghiên cứu trước đó vẫn chưa được kiểm chứng trên bộ dữ liệu khung xương. Kết quả so sánh giữa phương pháp đề xuất trong đề tài này với các nghiên cứu khác được trình bày trong Bảng 4. Tiêu chí lựa chọn kết quả và phương pháp thử nghiệm là 1) nghiên cứu phải dựa trên nhận dạng sớm hành động dựa trên dữ liệu khung xương người, 2) việc sử dụng bộ dữ liệu NTU RGB +D 60 làm dữ liệu huấn luyện mô hình, 3) sử dụng thước đo Cross-Subject cho các thử nghiệm. Các phương pháp phải được so sánh dựa trên ba nguyên tắc chính này.

3. Kết luận

Bài báo này đề xuất một kiến trúc mới để truyền tải kiến thức từ Giáo viên sang Học sinh thông qua mô đun Chắt lọc kiến thức. Tại thời điểm này, chỉ cần sử dụng kĩ thuật Giảm số mẫu để tiết kiệm thời gian và thực hiện nhiều thử nghiệm hơn nữa để tìm ra giá trị tốt nhất của $\boldsymbol{\alpha, \beta_1, \beta_2}$ trong công thức (5). Mặc dù vậy, mô đun Chắt lọc kiến thức đã chứng minh được tính

hiệu quả của phương pháp khi cải thiện tỉ lệ chính xác trong nhận dạng hành động khi so sánh với Học sinh không có mô đun Chắt lọc kiến thức. Trong tương lai chúng tôi sẽ nghiên cứu hoàn chỉnh về nhận dạng hành động sớm, các thử nghiệm chính xác của $\boldsymbol{\alpha}, \boldsymbol{\beta_1}, \boldsymbol{\beta_2}$, cũng như kết quả sự ảnh hưởng của mô đun Chắt lọc kiến thức lên mô hình Học sinh không chỉ ở tỉ lệ quan sát 20% mà cả 40%, 60%, 80% và 100%.

TÀI LIỆU THAM KHẢO

[1] Mouloud, A. & Mohamed, H. 2021. Exploring Cohesion in Students' Essay Writing Production: The Case of Third Year English Foreign Language Students at Setif 2 University, Algeria. *Journal of Arabic Language Sciences and Literature*, V.13, N. 01, 511-530.

[2] Yan, S., Xiong, Y., & Lin, D., 2018, April. Spatial-temporal graph convolutional networks for skeleton-based action recognition. In Proceedings of the *AAAI conference on artificial intelligence* (Vol. 32, No. 1).

[3] Shi, L., Zhang, Y., Cheng, J., & Lu, H., 2019. Two-stream adaptive graph convolutional networks for skeleton-based action recognition. In Proceedings of the *IEEE/CVF conference on computer vision and pattern recognition* (pp. 12026-12035).

[4] Shi, L., Zhang, Y., Cheng, J., & Lu, H., 2020. Skeleton-based action recognition with multi-stream adaptive graph convolutional networks. *IEEE Transactions on Image Processing*, 29, 9532-9545.

[5] Shahroudy, A., Liu, J., Ng, T. T., & Wang, G., 2016. Ntu rgb+ d: A large scale dataset for 3d human activity analysis. In Proceedings of the *IEEE conference on computer vision and pattern recognition* (pp. 1010-1019).

[6] Kay, W., Carreira, J., Simonyan, K., Zhang, B., Hillier, C., Vijayanarasimhan, S., ... & Zisserman, A., 2017. *The kinetics human action video dataset*. arXiv preprint arXiv:1705.06950.

[7] Lie, W. N., Huang, Y. J., Chiang, J. C., & Fang, Z. Y., 2021, September. High-Order Joint Information Input For Graph Convolutional Network Based Action Recognition. In 2021 *IEEE International Conference on Image Processing*, ICIP), pp. 1064-1068). IEEE.

[8] Wang, X., Hu, J. F., Lai, J. H., Zhang, J., & Zheng, W. S., 2019. Progressive teacher-student learning for early action prediction. In Proceedings of the *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 3556-3565).

[9] Zhang, P., Lan, C., Xing, J., Zeng, W., Xue, J., & Zheng, N., 2019. View adaptive neural networks for high performance skeleton-based human action recognition. IEEE transactions on pattern analysis and machine intelligence, 41(8), 1963-1978.

[10] Weng, J., Jiang, X., Zheng, W. L., & Yuan, J., 2020. Early action recognition with category exclusion using policy-based reinforcement learning. *IEEE Transactions on Circuits and Systems for Video Technology*, 30(12), 4626-4638.

[11] Ke, Q., Bennamoun, M., Rahmani, H., An, S., Sohel, F., & Boussaid, F., 2019. Learning latent global network for skeleton-based action prediction. *IEEE Transactions on Image Processing*, 29, 959-970.

[12] Wang, R., Liu, J., Ke, Q., Peng, D., & Lei, Y., 2021. *Dear-net: Learning diversities for skeleton-based early action recognition*. IEEE Transactions on Multimedia.

[13] Li, G., Li, N., Chang, F., & Liu, C., 2021. Adaptive graph convolutional network with adversarial learning for skeleton-based action prediction. *IEEE Transactions on Cognitive and Developmental Systems*, 14(3), 1258-1269.

ABSTRACT

Early action recognition using sequence skeleton data

Pham Huy Hoang[1], Bui Ngoc Dung[2*], Nguyen Son Anh[1],
Le Kien Truc[2] and Tran Nguyen Hoang[3]

[1]*Faculty of International Education, University of Transport and Communications*

[2]*Faculty of Information Technology, University of Transport and Communications*

[3]*Faculty of Information Technology, East Asia University of Technology*

Early action recognition is about predicting the labels of actions before they are completely finished, this is an application for medical monitoring, security monitoring, autonomous driving and human interaction. computer. Different from the traditional action recognition task that aims at recognition from a complete action sequence, early action recognition is forced to provide labels of actions from a part of the action sequence or with executions. incomplete action. In this article, the Knowledge Distillation – Attention-enhanced Adaptive Graph Convolutional Neural Network, KD-AAGCN) model is proposed to transfer knowledge from Teachers to Students. The results show that the accuracy of the proposed method is higher than the method that does not use the Knowledge Distillation module

Keywords: early action recognition, deep learning, knowledge distillation.